

AIを用いた楽曲制作に関する検討

1532117 秋場 翼

1532151 松元 孝樹

指導教員：中村 直人 教授

平成31年度

目次

第1章	序論	1
1.1	研究の背景と目的	1
1.1.1	AIの始まり	1
1.1.2	第1次AIブーム	2
1.1.3	第2次AIブーム	2
1.1.4	第3次AIブームの始まり	3
1.1.5	第3次AIブームの現在	3
1.1.6	様々なAI楽曲作成サービス	5
1.2	本論文の構成	5
第2章	理論	6
2.1	AIを用いた楽曲作成	6
2.1.1	MIDI	6
2.1.2	Magenta	6
2.1.3	MIDI	7
2.2	機械学習に適した開発環境について	7
2.2.1	CUDA	7
2.2.2	開発環境	9
第3章	実験内容	11
3.1	モデルによる違い	11
3.1.1	MelodyRNN	11
3.1.2	PolyphonyRNN	14
3.2	学習回数による違い	14
3.3	ノード数による違い	14
第4章	楽曲制作	15
4.1	Melody_rnnを使用して学習モデルを作成	15
4.1.1	NoteSequenceの作成	15
4.1.2	学習の開始	16
4.1.3	音楽データの作成	17
4.1.4	事前に学習済のモデルを使用	17
4.2	Polyphony_rnnを使用して学習モデルを作成	18
4.2.1	NoteSequenceの作成	18
4.2.2	学習の開始	18
4.2.3	音楽データの作成	19

第 5 章 結論	20
5.1 今後の課題	21
謝辞	22
参考文献	23

目 次

1.1	チューリングテストを合格した EugeneGoostman (引用： http://www.itmedia.co.jp/news/articles/1807/26/news014.html)	1
1.2	クイズ番組に出演する Watson (http://www.swift-web.org/cp-bin/blogn/index.php?e=1023)	4
1.3	多種多様なスマートスピーカー	4
2.1	magenta による MIDI 音楽データ生成までのプロセス	7
2.2	Docker 用 NVIDIA コンテナランタイム (引用： https://github.com/NVIDIA/nvidia-docker)	9
3.1	basic_rnn のモデル (1)	11
3.2	basic_rnn のモデル (2)	12
3.3	三つのモデルについて	12
3.4	lookback_rnn のモデル	13
3.5	attention_rnn のモデル	14

表 目 次

2.1 開発環境	10
--------------------	----

第1章 序論

1.1 研究の背景と目的

1.1.1 AIの始まり

AIの概念の始まりは,1950年にアラン・チューリングが提唱したチューリングテストである [1]. チューリングテストとは, 男性、女性、質問者の3人でおこなわれ, 目的は質問者がどちらが男性でどちらが女性かを当てるゲームである. 会話は文字だけでおこない, 男性は質問者を間違わせるように振舞い, 逆に女性は質問者を助けるように振舞う. このゲームの男性の代わりに機械がなり, 質問者が二人の人間を相手にした時と同じくらいの間違いを, 人間と機械のペアにも起こすことができれば, 機械は知性を持っているとする. また, チューリングテストを受ける機械はどんな技術を使っても良く, 機械を作った人が、その機械の動作の仕様をきちんと説明できないようなものであってもかまわないということを認めている. この概念が提唱されてから初めてチューリングテストに合格したのは,2014年にレディング大学で開催された「Turing Test 2014」で発表された, ウクライナ在住の13歳の少年が開発した「Eugene Goostman」というプログラムだった.

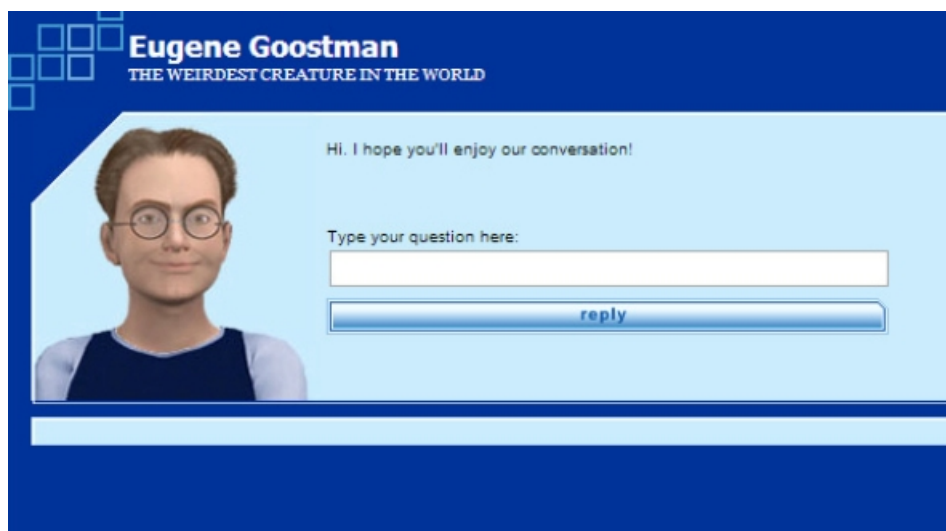


図 1.1: チューリングテストを合格した EugeneGoostman
(引用 : <http://www.itmedia.co.jp/news/articles/1807/26/news014.html>)

1.1.2 第1次 AI ブーム

その後、次の AI ブームは 1950 年代後半から 1960 年代に起きた。この時代になり初めて AI (Artificial Intelligence, 人工知能) という言葉がダートマス会議で用いられた。この会議は 1956 年に米ニューハンプシャー州のダートマス大学で開催され、コンピュータ研究者たちの研究成果を発表し合う研究発表会である。[7] この会議の発起人であるジョン・マッカーシー氏が AI という言葉を The Dartmouth Summer Research Project on Artificial Intelligence[2] の中で用いた。また、この会議で初めての人工知能プログラムと言われる“Logic Theorist”と呼ばれる数学原理をコンピュータで証明するデモンストレーションが行われ、当時のコンピュータはせいぜい四則演算が限界だったため、これは画期的な成果といえた。

他にも、マサチューセッツ工科大学のジョセフ・ワイゼンバウム氏が 1966 年に作成した単純な自然言語処理プログラム「ELIZA」が発表された。ただ、ELIZA はそのプログラムはパターン照合を適用しているためパターンにない会話はできないため曖昧な事柄に対応できない。また、人工知能の理解は文字列だけにしか及ばず、これを記号に結びつけることが出来ないという「シンボルグラウンディング問題」が指摘される。例えば、「馬」と「縞(シマ)」、それぞれの概念を知っている人はシマウマ＝「馬」＋「シマ」だと理解できるが、人工知能にはそれができない、というものである。

1.1.3 第2次 AI ブーム

1980 年代に入り、家庭にコンピュータが普及したことにより第二次ブームが発生しました。「知識」(コンピュータが推論するために必要な様々な情報を、コンピュータが認識できる形で記述したもの)を与えることで人工知能(AI)が実用可能な水準に達し、多数のエキスパートシステムとよばれる、専門分野の知識を取り込んだ上で推論することで、その分野の専門家のように振る舞うプログラムが生み出された。日本では、政府による「第五世代コンピュータ」と名付けられた大型プロジェクトが推進された。しかし、当時はコンピュータが必要な情報を自ら収集して蓄積することはできなかったため、必要となる全ての情報について、人がコンピュータにとって理解可能なように内容を記述する必要があった。世にある膨大な情報全てを、コンピュータが理解できるように記述して用意することは困難なため、実際に活用可能な知識量は特定の領域の情報などに限定する必要があった。こうした限界から、1995 年頃から再び冬の時代を迎えた。第一次ブームと比較してコンピュータの小型化・性能が高まっており、ある程度はこれらの試みは成功したが、知識を教え込む作業が非常に煩雑であること、例外処理や矛盾したルールに柔軟に対応することが出来ませんでした。日常世界を見渡してみると、これらの例外処理や矛盾したルールは非常に多く、知識を教え込む作業が非常に困難なことから、第二次 AI ブームは自然に消滅へと向かってし

まいりました。その後、1990年代半ばに Windows95 の登場、インターネットの普及、検索エンジンの高性能化が進み、世界中にいる誰もが簡単に大量のデータを扱える時代に突入しました。

1.1.4 第3次 AI ブームの始まり

第二次 AI ブームでのエキスパートシステムが壁にぶつかった問題として、日常世界には例外処理や矛盾したルールが非常に多く、知識を教え込む作業が非常に困難というのがありました。これらを解決する手段として「機械学習」や「ディープラーニング」にてコンピュータが自らが学んでいくという手法が第二次 AI ブームの時代から研究されていましたが、実用化するためにはコンピュータの性能が追い付いていなかった。しかし、2000年代に入り、コンピュータの小型化・性能向上に加えインターネットの普及、クラウドでの膨大なデータ管理が容易となったことで実現可能なレベルとなり、第三次 AI ブームが沸き起こりました。2006年にはニューラルネットワークの代表的な研究者であるジェフリー・ヒントンの研究チームが、制限ボルツマンマシンによるオートエンコーダの深層化に成功し、再び注目を集めるようになった。この際、発表した論文から、これまでの多層ニューラルネットワークよりもさらに深いネットワーク構造を意味する、ディープネットワークの用語が定着した。2011年に IBM ワトソンがクイズ番組難解な質問と独特の解答方法で知られる人気クイズ番組「ジョパディ！」に出場した。ワトソンが読み込んだ本や映画の脚本、百科事典などは合計 100 万冊。公平を期すため、インターネットには接続しておらず、“頭の中”の蓄積だけが頼りだ。このときまで、機械学習のほとんどは、ラベル付きデータの量に依存していた。キャットペーパーにより、機械がラベルのない生データでも処理することができ、そしておそらく、人間が予備知識を持たないデータですら処理できることが示された。

1.1.5 第3次 AI ブームの現在

2014年には Amazon.com からスマートスピーカと呼ばれる対話型の音声操作に対応した AI アシスタント機能を持つスピーカーである Amazon Echo が発売され、その後 Google や Amazon、IBM によって様々なスマートスピーカーが商品化された。現在ではスマートフォンにも Siri という AI が搭載されるなどその存在は非常に身近になっており、その種類も非常に多岐にわたる。

囲碁や将棋、チェスなどの競技においても、プロに AI が勝利するなどその精度は以前から高いが、その AI は一つの競技でしか使用できない特化型人工知能 (AGI) でありつた。しかし、英 DeepMind が発表した AlphaZero という様々なボードゲームに対応でき



図 1.2: クイズ番組に出演する Watson
(<http://www.swift-web.org/cp-bin/blogn/index.php?e=1023>)



図 1.3: 多種多様なスマートスピーカー

る汎用性を持った AI が発表され, 汎用人工知能 (GAI) の成長も著しい。
自然言語処理を用いた芸術の分野では, 2012 年にスタートした人工知能を使って小説を生成するプロジェクトが「星新一賞」の第一審査を通過した.[5] また, 絵画や音楽に関

しても AI が作成した肖像画が米競売大手クリスティーズのオークションで 43 万 2500 ドル（約 4900 万円）で落札され, AI を用いて新しい作品を作るものが出回っている.[6]

1.1.6 様々な AI 楽曲作成サービス

AI を用いた楽曲作成サービスは Amper Music という「作成したい音楽ジャンル」と「曲の長さ」を指定すれば, AI がオリジナル曲を作曲してくれるサービスです. 作成した曲は, テンポを変えたり, 楽器を追加したりと後からも編集できるようにもなっている. また, Jukedek 本研究では AI による楽曲生成についての実証実験を行う. Google brain によって公開されている Tensorflow のライブラリである Magenta は AI Duet やそのライブラリを用いて学習データやノード数による楽曲の生成結果の違いを比較, 検証し, AI による楽曲制作が有用なものか調査する.

1.2 本論文の構成

本論文の構成は以下の通りである.

第 1 章では本論文の背景と目的について述べている.

第 2 章では本論文で利用する理論について述べている.

第 3 章では実験内容について述べている.

第 4 章では楽曲制作について述べている.

第 5 章では AI を用いた楽曲制作についての本研究の結論について述べている.

第2章 理論


2.1 AIを用いた楽曲作成

2.1.1 MIDI

MIDI とオーディオデータの形式について述べるパソコンで用いる音楽データには大きく分けて二つある. 一つ目はオーディオデータといい波形の情報を記録する形式である. 二つ目がMIDIである AI による曲制作では主に MIDI ファイルの音楽データを使用する. MIDI ファイルには実際の音ではなく音楽の演奏情報 (音の高さや長さなど) である. 本研究で用いる AI はこの MIDI ファイルの情報を元に学習をする. また入出力の際もこの規格を用いる.

2.1.2 Magenta

本研究で使用する Magenta[1] は音楽などを TensorFlow を使って機械学習するライブラリであり, Google Brain が GitHub 上に公開されている OSS である. Magenta ではまず学習させたい音楽の MIDI データを NoteSequence (magenta が扱うファイル形式) とよばれるデータフォーマットに変更する. それを学習用データセットと評価用データセットに変換したあと学習を行う. このとき, 一度に学習させるデータの数, 学習を行う回数, ノード数を設定する. これをパッケージ化し, MIDI ファイルとして新たに楽曲を生成するという流れである. これを図 2.1 に示す.



2.1.3 MIDI

パソコンで用いる音楽データには大きく分けて二つある。一つ目はオーディオデータといい波形の情報を記録する形式である。二つ目が MIDI である AI による曲制作では主に MIDI ファイルの音楽データを使用する。MIDI ファイルには実際の音ではなく音楽の演奏情報（音の高さや長さなど）である。本研究で用いる AI はこの MIDI ファイルの情報を元に学習をする。また入出力の際もこの規格を用いる。

2.2 機械学習に適した開発環境について

2.2.1 CUDA

CUDA というのは、NVIDIA が開発している GPU 上でプログラミングをするためのソフトウェアプラットフォームになります。含まれるものとしては、CUDA を実行形式に変えるコンパイラみたいなもの、それをサポートする SDK、ライブラリ、あとはデバッグツール群ですね。——CUDA を導入することによって、何がどう変わるのでしょうか？橋本：一般的に行われるプログラミングというのは、いわゆる順次処理に適したものです。それを並列化していくなかで、単に複数のプロセッサで動かせばいいということではなく、いかに無駄なく並列化するのか、というのが重要なのですが、これが非常に難しい問題なんですね。特に NVIDIA の GPU には非常に多くのプロセッシングユニットが含まれています。そして CUDA にはこれらが無駄なく活用するためのいろいろなテクニックが組み込まれています。CUDA のプログラムを実行する

にあたって、GPUはグループ化されているんですね。GPUにはたくさんのコアがありますが、プログラムは1個1個のコアを認識するのではなくて、ある一定の数でグループ化されていて、その各々のグループに対してセットのオペレーションを振り分けていくんです。これはどういうことかと言うと、コンピュータを実行するためには計算だけではなく、メモリのリードライトが必要です。実はこのメモリのリードライトってものすごく時間かかるわけですよ。だからプログラムをコアで実行しようとすると、最初にやるのはメモリリードなんです。まず、データが来るまでにすごく待ちます。計算をしたら次のデータがほしいので、また待たないといけません。すると時間軸上でプロセッサが動いてるのはココとココ（下記の画像の、上側のオレンジの部分）だけになるんです。GPUではテクスチャ処理などを実行するときに、ピクセルを順次に計算していくのですが、次のピクセルで読まなきゃいけないデータはある程度予測できるんです。必要なデータに事前にメモリーリクエストを出すんですよ。いわゆるスケジュールドアクセスですね。同じようなテクニックを使ってCUDAでも次の処理に必要なデータを先読みしようと。そうすることによって、計算処理があって、これを10スレッド走らせるときに、クロックを少しずつずらして実行していくんですね。そうするとプロセッサが無駄なく回るわけですよ。こういった処理をより書きやすくしたのがCUDAというわけです。ちなみに、CUDAの形式で書けばなんでも速くなるかという、そうではありません。各人は事前に、どこにどういうデータがあって、どういう風に割り当てて、どういう風にアクセスさせていくかということを設計しなければダメですね。CUDAの場合は設計が一番重要になってきます。

2.2.2 開発環境

前提としてディープラーニング（深層学習）などの用途で NVIDIA 社製 GPU ボードを利用する場合、ディープラーニング用フレームワーク等のソフトウェアを導入する前に 下記の NVIDIA 社製ソフトウェアを導入する必要があります。

- (1) CUDA Toolkit
- (2) PU ボード用ドライバーソフトウェア
- (3) 追加のライブラリ (cuDNN など)

Magenta プロジェクトが推奨している開発環境の構築には二つ方法があり、一つは Docker というコンテナ型の仮想化環境を構築できるオープンソースソフトウェアを用いる方法と、ローカル環境に Python のパッケージ管理システムである pip を用いて構築する方法の 2 つがある。

Docker を用いることで仮想化環境をクラウド上で共有できるサービスをである DockerHub を使用できるため、パッケージのインストールをおこなわずにコマンド一つで環境を構築できる。しかし、コンテナに GPU を割り当てることは現状では NVIDIA が公開している OSS の nvidia-docker という




図 2.2: Docker 用 NVIDIA コンテナランタイム
(引用 : <https://github.com/NVIDIA/nvidia-docker>)

本システムの開発環境を表 2.1 に示す.

表 2.1: 開発環境

OS	Ubuntu
CPU	Intel Core i5
メモリ	8GB
GPU	GeForce GTX 1060
使用ライブラリ	TensorFlow , magenta

本システムを使用し OS は Ubuntu を使用した. 使用するライブラリとして, ニューラルネットワークを構築できる Tensorflow を利用した.

第3章 実験内容

3.1 モデルによる違い

本研究では Magenta で用意されている 2 つの学習モデルを用いた。以下に示すモデルを用いて楽曲制作をそれぞれ行い，比較，検証する。

3.1.1 MelodyRNN

MelodeRNN は楽曲のメロディを制作するモデルである。MelodyRNN である 3 つのモデルを以下に示す。

(1) basic_rnn

前の状態を保持し，これを記憶または忘却する。時系列を学習することにより，次の音の予測を可能にしている。Lookback_rnn と Attention_rnn はこれを基に機能を追加したものである。




図 3.1: basic_rnn のモデル (1)




図 3.2: basic_rnn のモデル (2)

Lookback_rnn と Attention_rnn はこれを基に機能を追加したものである

basic_rnn



lookback_rnn


attention_rnn

- ・Recurrent Nevral Network というもの
- ・basic_rnnを拡張したものがlookback_rnnとattention_rnn
- ・どちらが優位ということはない
- ・入出力データはOne-hot vector

図 3.3: 三つのモデルについて

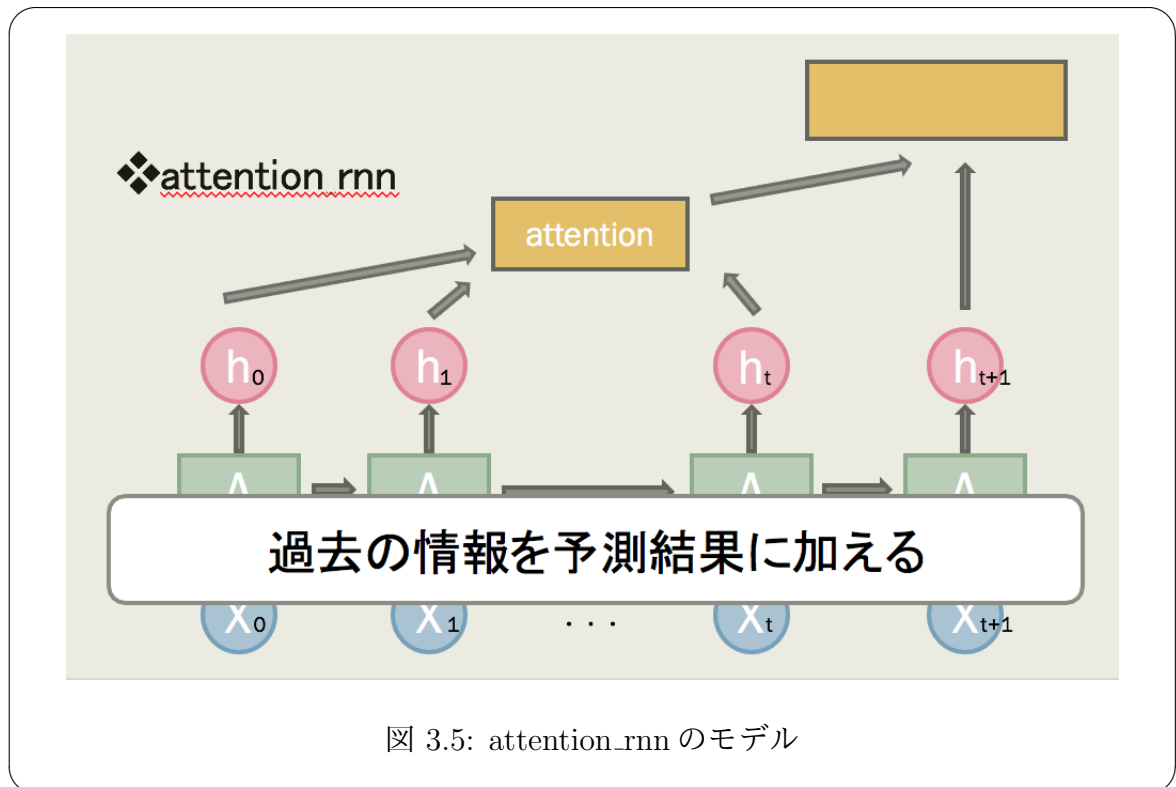
(2) lookback_rnn

Basic_rnn を基に， 1 小節前と 2 小節前の音， 拍数， 前の小節の繰り返しかどうかの情報を与え， 音楽の流れを掴もうとするもの．



(3) attention_rnn

basic_rnn を基に，過去の情報を予測結果に加えてこれによる繰り返しを捉えるもの．



3.1.2 PolyphonyRNN

複数の同時音のモデリングが可能になっており，複数音の響きを1つのかたまりとして捉えて学習しているモデルである．このモデルを使用することで，伴奏も含めた楽曲の生成が可能である

上記のモデルを用いて制作を行い，それぞれの違いと有用性について検証する．

3.2 学習回数による違い

学習回数を変更して楽曲制作を行い，それぞれの違いと有用性について検証する．

3.3 ノード数による違い

ノード数を変更して楽曲制作を行い，それぞれの違いと有用性について検証する．

第4章 楽曲制作

4.1 Melody_rnn を使用して学習モデルを作成

4.1.1 NoteSequence の作成

NoteSequence とは MIDI データから作成されるプロトコルバッファである。プロトコルバッファとは Google が 2008 年にオープンソース化したバイナリベースのデータフォーマットである。既存の技術としては XML や JSON などのテキストベースのデータフォーマットがあるが、プロトコルバッファはバイナリフォーマットであるので、アプリケーション間でデータ構造の送受信をする際に少ないデータ量ですむという特徴がある。スキーマ言語はなぜ重要なのか、そういう時代になったからだ。我々が単一 RDB に接続する単一の Web アプリだけを書いていた時代はとうの昔に終わった。データはあちこちのいろんなストレージ技術で保存されているかもしれないし、バックエンドも単一サービスではなくて分割されているかもしれないし、クライアントは web 版、iOS 版、Android 版があってひょっとしたらそれぞれ別の言語で実装されており、外部開発者向けに API も公開しなければならない。だから、そこら中でデータをシリアライズするしデシリアライズするし、通信の両端で解釈に矛盾が無いようにすり合わせる必要がある。でも、すりあわせの目的でいちいち人間と自然言語で会話するのは苦痛なので、私たちは機械処理可能なコードで語りたい。だから、どういうデータがやってくるのかきちんと宣言的 DSL で定義しておきたい。そこでスキーマ言語だ。JSON Schema が広がりつつあるのもたぶんそういう理由だし、そもそも Protobuf 自体も Google が社内で同じ問題にぶち当たって発明されたんだったような気がする。自分の管轄領域内に閉じたデータ構造であれば、スキーマとか型宣言とか細かい縛りなしで軽量に進めるのもありだ。しかし、他人の領域との界面はしっかり定義しておいた方が良い。スキーマ定義という税金を支払わないとその分のツケはどこかで回ってきて、1 時間掛かる E2E テストがこけるとか、週次変更レビュー合同会議の発足とか、そういうやつで支払うことになる。スキーマ定義さえあれば、web クライアント開発用の、バックエンド開発用の、アプリ開発用の言語に向けて対応するデータ構造定義を自動生成して、矛盾なくすべてをメンテナンスできる。通信の両端でスキーマさえ合致していれば、シリアライゼーション形式を合わせるのはむしろ間違えづらい。だから、JSON でも Protobuf のデフォルトのそれでも、MessagePack でも XML でも好き

にすれば良い。ちなみに、Protobufで定義したデータ構造はProtobuf標準形式の他にJSONにもきちんとシリアル化できる。NoteSequenceの作成は以下に示すコマンドで作成できる。

`-input_dir` で学習させる MIDI データのディレクトリの絶対パスを指定し、`-output_file` で NoteSequence の出力先のディレクトリを指定する。

```
convert\_dir\_to\_note\_sequences \
--input\_dir=\$INPUT\_DIRECTORY \
--output\_file=\$SEQUENCES\_TFRECORD \
--recursive
```

次に作成した NoteSequence のデータセットを学習用と評価用に分割するために以下に示すのコマンドを実行する。

`-config` で使用する RNN を指定する。`-input_dir` で NoteSequence の絶対パスを指定し、`-output_file` で分割した NoteSequence の出力先のディレクトリを指定する。`-eval_ratio` で NoteSequence のデータを何パーセント学習用に用いるかを指定する。コマンドの場合は 10% が学習用のデータになる。

```
melody_rnn_create_dataset \
--config=<one of 'basic_rnn', 'lookback_rnn', or 'attention_rnn'> \
--input=/tmp/notesequences.tfrecord \
--output_dir=/tmp/melody_rnn/sequence_examples \
--eval_ratio=0.10
```

4.1.2 学習の開始

作成した NoteSequence から学習モデルを作成するために以下のコマンドを実行する。

`-config` で学習に使用する学習モデルを指定、`-rundir` で学習のために用意した NoteSequence を指定し、`-sequence_example_file` で学習モデルの出力先のディレクトリを指定する。`-hparams` でメモリの使用量を指定し、`-rnn_layer_size` で中間層のノード数を指定し、`-num_training_steps` で学習回数を設定する。

```
melody_rnn_train \
--config=attention_rnn \
--run_dir=/tmp/melody_rnn/logdir/run1 \
--sequence_example_file=/tmp/melody_rnn/training_melodies.tfrecord \
--hparams="batch_size=64,rnn_layer_sizes=[64,64]" \
--num_training_steps=20000
```

4.1.3 音楽データの作成

以下に示すコマンドで学習モデルに入力する.

`-config` で学習に使用する学習モデルを指定,`-rundir` で学習済みのモデルを指定し,`-output_dir` で音楽データの出力先のディレクトリを指定する. `-num_outputs` で生成する音楽データの個数を指定し,`-num_steps` で`-hparams` でメモリの使用量を指定し,`-rnn_layer_size` で中間層のノード数を指定し,`-primer_melody` で学習モデルに入力する最初の音程を MIDI の形式で指定する.

```
melody_rnn_generate \  
--config=attention_rnn \  
--run_dir=/tmp/melody_rnn/logdir/run1 \  
--output_dir=/tmp/melody_rnn/generated \  
--num_outputs=10 \  
--num_steps=128 \  
--hparams="batch_size=64,rnn_layer_sizes=[64,64]" \  
--primer_melody="[60]"
```

4.1.4 事前に学習済のモデルを使用

また,Magenta プロジェクトにすでに学習済のモデルが存在するのでそれを使用して音楽データを作成することもできる. 生成には `mag` バンドファイルが必要になるので magenta の Github に公開されているので,それをダウンロードしてくる. その後以下に示すコマンドを実行する事で生成することができる.

`-config` で学習に使用する学習モデルを指定,`-rundir` で学習済みのモデルを指定し,`-output_dir` で音楽データの出力先のディレクトリを指定する. `-num_outputs` で生成する音楽データの個数を指定し,`-num_steps` で`-hparams` でメモリの使用量を指定し,`-rnn_layer_size` で中間層のノード数を指定し,`-primer_melody` で学習モデルに入力する最初の音程を MIDI の形式で指定する.

```
melody_rnn_generate \  
--config=${CONFIG} \  
--bundle_file=${BUNDLE_PATH} \  
--output_dir=/tmp/melody_rnn/generated \  
--num_outputs=10 \  
--num_steps=128 \  
--primer_melody="[60]"
```

4.2 Polyphony_rnn を使用して学習モデルを作成

PolyphonyRNN を使用してする手順としては、大まかな流れは同じであるが`-config` で使用する RNN を指定する必要がないという違いがある

4.2.1 NoteSequence の作成

NoteSequence の作成は以下に示すコマンドで作成できる。

`-input_dir` で学習させる MIDI データのディレクトリの絶対パスを指定し、`-output_file` で Notesequenece の出力先のディレクトリを指定する。

```
convert\_dir\_to\_note\_sequences \
--input\_dir=\$INPUT\_DIRECTORY \
--output\_file=\$SEQUENCES\_TFRECORD \
--recursive
```

次に作成した NoteSequence のデータセットを学習用と評価用に分割するために以下に示すのコマンドを実行する。

`-input_dir` で NoteSequence の絶対パスを指定し、`-output_file` で分割した Notesequenece の出力先のディレクトリを指定する。 `-eval_ratio` で Notesequenece のデータを何パーセント学習用に用いるかを指定する。 コマンドの場合は 10% が学習用のデータになる。

```
polyphony_rnn_create_dataset \
--input=/tmp/notesequences.tfrecord \
--output_dir=/tmp/polyphony_rnn/sequence_examples \
--eval_ratio=0.10
```

4.2.2 学習の開始

作成した NoteSequence から学習モデルを作成するために以下のコマンドを実行する。

`-config` で学習に使用する学習モデルを指定、`-rundir` で学習のために用意した Notesequenece を指定し、`-sequence_examplefile` で学習モデルの出力先のディレクトリを指定する。 `-hparams` でメモリの使用量を指定し、`-rnn_layer_size` で中間層のノード数を指定し、`-num_trainingsteps` で学習回数を設定する。

```
polyphony_rnn_train \
--run_dir=/tmp/polyphony_rnn/logdir/run1 \
--sequence_example_file=/tmp/polyphony_rnn/training_tracks.tfrecord \
--hparams="batch_size=64,rnn_layer_sizes=[64,64]" \
--num_training_steps=20000
```

4.2.3 音楽データの作成

以下に示すコマンドで学習モデルに入力する.

`--config` で学習に使用する学習モデルを指定,`--rundir` で学習済みのモデルを指定し,`--output_dir` で音楽データの出力先のディレクトリを指定する. `--num_outputs` で生成する音楽データの個数を指定し,`--num_steps` で`--hparams` でメモリの使用量を指定し,`--rnn_layer_size` で中間層のノード数を指定し,`--primer_melody` で学習モデルに入力する最初の音程を MIDI の形式で指定する.

```
polyphony_rnn_generate \  
--run_dir=/tmp/polyphony_rnn/logdir/run1 \  
--hparams="batch_size=64,rnn_layer_sizes=[64,64]" \  
--output_dir=/tmp/polyphony_rnn/generated \  
--num_outputs=10 \  
--num_steps=128 \  
--primer_pitches="[67,64,60]" \  
--condition_on_primer=true \  
--inject_primer_during_generation=false
```


第5章 結論

5.1 今後の課題

aaa

謝辭

参考文献

- [1] A. M. Turing (1950), "COMPUTING MACHINERY AND INTELLIGENCE"
<https://www.csee.umbc.edu/courses/471/papers/turing.pdf>
- [2] J. McCarthy,Dartmouth College M. L. Minsky,Harvard University N.
Rochester,I.B.M. Corporation C.E. Shannon,Bell Telephone Laboratories(1955),
"A PROPOSAL FOR THE DARTMOUTH SUMMER RESEARCH PROJECT
ON ARTIFICIAL INTELLIGENCE"
<http://www-formal.stanford.edu/jmc/history/dartmouth/dartmouth.html>
- [3] Quoc Le Marc'Aurelio Ranzato Rajat Monga Matthieu Devin Kai Chen Greg
Corrado Jeff Dean Andrew Ng(2012) "Building High-level Features Using Large
Scale Unsupervised Learning" <https://storage.googleapis.com/pub-tools-public-publication-data/pdf/38115.pdf>
- [4] Google Brain チーム,"Magenda" <https://github.com/tensorflow/magenta>
- [5] 財経新聞,"人工知能を使って執筆した小説が星新一賞一次選考を通過"
<https://www.zaikai.co.jp/article/20160323/299468.html>
- [6] YAHOO ニュース,"AI 絵画、大手オークションで初の落札 予想額の 40 倍超"
<https://headlines.yahoo.co.jp/hl?a=20181026-00010002-afpbnews-v-int>
- [7] (社) 人工知能学会 "人工知能の話題"
<https://www.ai-gakkai.or.jp/whatsai/AItopics5.html>
- [8] マイナビニュース,"XML はもう不要!? Google 製シリアルライズツール「Protocol Buffer」"
<https://news.mynavi.jp/article/20080718-protocolbuffer/>